Laboratoria: Estymacja punktowa i metody symulacyjne Monte Carlo

Zadanie. Problem niemieckich czołgów (German Tank Problem)

Kontekst historyczny:
Podczas II Wojny Światowej aliancki wywiad wojskowy szacował produkcję niemieckich czołgów tradycyjnymi metodami na ok. 1400 sztuk miesięcznie. Alianci przechwycili jednak małą liczbę czołgów i odczytali z ich części (skrzynie biegów, koła) numery seryjne. Zadanie oszacowania całkowitej wielkości produkcji (N) powierzono statystykom. Wyniki analizy matematycznej wskazały na ok. 246 sztuk. Po wojnie dokumenty produkcyjne potwierdziły, że rzeczywista produkcja wynosiła 255 sztuk. Wywiad matematyczny osiągnął spektakularną precyzję, dysponując zaledwie garścią liczb.

Model matematyczny:

Zakładamy, że wyprodukowano N czołgów oznaczonych kolejnymi liczbami od 1 do N. Przechwycono n-elementową próbę maszyn o numerach $X_1, \ldots, X_n$. W celach symulacyjnych modelujemy to jako losowanie z rozkładu jednostajnego na przedziale $[0, N]$ (wersja ciągła upraszcza obliczenia, zachowując esencję problemu). Porównujemy dwa estymatory nieznanego maksimum N:

1. **Estymator Metody Momentów (MM):** Bazuje na wartości oczekiwanej rozkładu jednostajnego ($E(X) = N/2$), co daje wzór: $\hat{N}_{MM} = 2\bar{X}$.
2. **Poprawiony Estymator Największej Wiarogodności (MLE):** Klasyczny estymator MLE, czyli $\max(X)$, z natury zawsze zaniża wynik (bo szansa na to, że złapiemy akurat ostatni wyprodukowany czołg, jest mała). Aby usunąć to obciążenie, stosuje się teoretyczną korektę: $\hat{N}_{MLE} = \max(X) \cdot \frac{n+1}{n}$.

Ważna intuicja: Rola wielokrotnego powtarzania eksperymentu w analizie estymatorów

W praktycznych zastosowaniach statystyki dysponuje się zazwyczaj **tylko jedną próbką** o określonej liczebności n, zebraną w rzeczywistym świecie (tak jak statystycy podczas wojny dysponowali konkretnym, pojedynczym zbiorem przechwyconych numerów seryjnych). Na podstawie tej jednej próby wyliczany jest ostateczny wynik. Ta pojedyncza próba jest jednak zawsze realizacją pewnego procesu losowego, co oznacza, że niesie w sobie element przypadkowości.

Celowe powtarzanie tego samego eksperymentu losowego wielokrotnie w warunkach symulacyjnych nie służy odtworzeniu realiów historycznych, lecz zbadaniu teoretycznych właściwości rozważanych estymatorów:

- **Badanie obciążenia:** Wielokrotne losowanie nowych prób z tego samego rozkładu pozwala sprawdzić, wokół jakiej wartości skupiają się wyniki danej metody w długiej serii powtórzeń. Chcemy zweryfikować empirycznie, czy średnia z uzyskanych oszacowań pokrywa się z prawdziwym, nieznanym parametrem N (czyli czy estymator jest nieobciążony).
- **Badanie wariancji:** Analiza rozrzutu wyników pomiędzy poszczególnymi powtórzeniami pozwala ocenić stabilność danej metody. Interesuje nas wskazanie estymatora o **najmniejszej wariancji** – takiego, który jest odporny na ślepy los podczas pobierania próby i w każdym pojedynczym świecie generuje wynik leżący blisko rzeczywistej wartości parametru, minimalizując ryzyko podjęcia błędnej decyzji na podstawie pojedynczej próby.

1. Projekt funkcji symulującej przechwycenie czołgów

Funkcja `tank_experiment()` generuje losową próbę n czołgów z rozkładu jednostajnego o zadanym, ustalonym na potrzeby symulacji maksimum `N_true`. Następnie, na podstawie wygenerowanego wektora danych `x`, funkcja oblicza wartości obu estymatorów dla tej pojedynczej realizacji próby losowej.

```
# Funkcja symulujaca proces losowania proby i wyznaczania estymatorow
tank_experiment <- function(n, N_true = 255) {

  # Generowanie proby n-elementowej z rozkladu jednostajnego o znanym
    maksimum N_true
  x <- runif(n, min = 0, max = N_true)

  # Oblicz estymator metody momentow (dwukrotnosc sredniej)
  N_hat_mm <- [UZUPELNIJ]

  # Oblicz poprawiony estymator MLE (maksimum pomnozone przez poprawke)
  N_hat_mle <- [UZUPELNIJ]

  # Zwracamy nazwany wektor z wynikami obu metod
  return(c(Metoda_Momentow = N_hat_mm, MLE = N_hat_mle))
}
```

2. Symulacja Monte Carlo i wizualizacja wyników

Zakładamy, że dysponujemy próbą zaledwie $n = 5$ czołgów, a prawdziwa wielkość produkcji wynosi $N = 255$. Przeprowadzamy symulację dla wielokrotnego powtórzenia eksperymentu, a uzyskane dane reorganizujemy za pomocą funkcji `stack()`, by przygotować je do wizualizacji za pomocą pakietu `ggplot2`.

```
N_sim <- 500
N_true <- 255

# Uruchomienie symulacji (powtorzenie eksperymentu N_sim razy)
# t() transponuje domyslny wynik z replicate, aby kazda realizacja byla
    wierszem
results <- as.data.frame(t(replicate(N_sim, tank_experiment(n = 5, N_
    true = N_true))))

# Reorganizacja danych do formatu dlugiego (kolumny 'values' oraz 'ind
    ')
results_long <- stack(results)

# --- WIZUALIZACJA ---
library(ggplot2)

ggplot(results_long, aes(x = ind, y = values, color = ind)) +
  # Surowe realizacje z symulacji (punkty w tle)
  geom_jitter(alpha = 0.3, width = 0.15) +

  # Linia referencyjna oznaczajaca rzeczywista wielkosc produkcji (255)
  geom_hline(yintercept = N_true, linetype = "dashed", color = "red",
    size = 1) +

  # Dodanie sredniej empirycznej (punkt) i odchylenia standardowego (
    wasy)
  stat_summary(fun.data = "mean_sdl", color = "black", size = 0.8) +
```

```
theme_minimal() +
labs(title = "German Tank Problem (n = 5, True N = 255)",
     x = "Metoda estymacji", y = "Oszacowana liczba czolgow") +
theme(legend.position = "none")
```

3. Pytania analizujące do zadania

- Porównaj położenie czarnych punktów (średnich empirycznych) z czerwoną linią referencyjną. Co można powiedzieć o obciążeniu obu estymatorów?
- Spójrz na długość czarnych wąsów (odchylenie standardowe) oraz rozrzut punktów w tle. Wyobraź sobie, że dysponujesz tylko jedną, konkretną próbką danych. Którego wzoru bezpieczniej użyć przy podejmowaniu decyzji i dlaczego?

Zadanie. Paradoks Inspekcji (Dlaczego autobusy zawsze się spóźniają?)

Kontekst:
Autobusy miejskie kursują średnio co 10 minut. Jeśli pasażer przychodzi na przystanek w całkowicie losowym momencie, intuicja podpowiada, że powinien czekać średnio połowę tego czasu, czyli 5 minut. W rzeczywistości średni czas oczekiwania w takim modelu wynosi równe 10 minut. Zjawisko to nosi nazwę paradoksu inspekcji (lub paradoksu czasu oczekiwania).

Model matematyczny:

1. **Czas między przyjazdami autobusów:** Zakładamy, że odstępy czasowe pomiędzy kolejnymi autobusami są niezależnymi zmiennymi losowymi o rozkładzie wykładniczym z parametrem $\lambda = 0.1$ (co oznacza, że intensywność przyjazdów wynosi 0.1 autobusu na minutę, a oczekiwany odstęp to $1/\lambda = 10$ minut).
2. **Moment przyjścia pasażera:** Pasażer pojawia się na przystanku w losowym momencie, co modelujemy za pomocą rozkładu jednostajnego na osi czasu – od momentu odjazdu pierwszego autobusu do momentu odjazdu ostatniego autobusu w symulacji.

Ważna intuicja: Losowy moment obserwacji a intuicja o średniej

W klasycznych zadaniach ze statystyki intuicja podpowiada, że losowy obserwator (pasażer) powinien zastać sytuację bliską średniej globalnej. Skoro oczekiwany odstęp między autobusami wynosi 10 minut, naturalnym oczekiwaniem jest, że średni czas czekania wyniesie połowę tego czasu.

Wielokrotne powtórzenie tego eksperymentu w warunkach symulacyjnych pozwala zbadać, dlaczego ta potoczna intuicja zawodzi:

- **Wpływ zmienności odstępów w przyjętym modelu:** Dla zadanego parametru $\lambda = 0.1$ odchylenie standardowe odstępów jest równe średniej i wynosi 10 minut (wariancja wynosi 100). Taki rozrzut oznacza, że w procesie często pojawiają się interwały znacznie dłuższe niż średnia. Wybór momentu przyjścia pasażera z rozkładu jednostajnego sprawia, że prawdopodobieństwo trafienia w dany interwał jest wprost proporcjonalne do jego długości.
- **Niereprezentatywność losowego wyboru:** Dłuższe interwały czasowe zajmują większą część rozważanego przedziału, przez co losowy pasażer trafia w nie z większym prawdopodobieństwem niż w interwały krótkie (jest to tzw. próbkowanie z wagą proporcjonalną do długości interwału). Symulacja komputerowa pozwala wykazać, że uzyskany wynik nie

wynika z błędu we wzorach, lecz ze specyfiki mechanizmu losowania, który drastycznie zawyża średni czas oczekiwania w stosunku do naiwnych oczekiwań.

1. Projekt funkcji symulującej pojedynczego pasażera

Do zweryfikowania tego paradoksu posłuży funkcja `bus_experiment()`. Jej zadaniem jest odtworzenie całego dnia na przystanku autobusowym oraz zmierzenie czasu, jaki losowy pasażer spędzi na czekaniu dla pojedynczej realizacji procesu losowego.

```
# Funkcja symulujaca jednego pasazera przychodzacego na przystanek
bus_experiment <- function(liczba_autobusow = 100) {

  # KROK 1: Odstepy (rozklad wykladniczy, srednia = 10) i momenty
   przyjazdow na osi czasu
  odstepy <- rexp(liczba_autobusow, rate = 0.1)
  momenty_przyjazdu <- cumsum(odstepy)

  # KROK 2: Pasazer trafia losowo (rozklad jednostajny) miedzy pierwszy
    a ostatni autobus
  moment_pasazera <- runif(1, min = momenty_przyjazdu[1], max = max(
   momenty_przyjazdu))

  # KROK 3: Wyznaczenie czasu oczekiwania na najblizszy autobus
  # Przefiltruj wektor 'momenty_przyjazdu', wybierajac tylko te wieksze
    od 'moment_pasazera'
  autobusy_po_pasazerze <- [UZUPELNIJ]

  # Wybierz pierwszy z tych autobusow i odejmij od niego 'moment_
   pasazera'
  czas_oczekiwania <- [UZUPELNIJ]

  return(czas_oczekiwania)
}
```

2. Symulacja Monte Carlo i analiza statystyczna

Aby empirycznie zweryfikować teoretyczne przewidywania dotyczące paradoksu inspekcji, należy powtórzyć powyższy eksperyment wielokrotnie ($N = 1000$ razy). Pozwoli to zasymulować zachowanie tysiąca niezależnych pasażerów trafiających w losowe momenty.

```
# Liczba symulowanych pasazerow
N_sim <- 1000

# Uruchomienie symulacji Monte Carlo - zbieramy wyniki do jednego
   wektora
czasy_czekania <- replicate(N_sim, bus_experiment(liczba_autobusow =
   100))

# --- ANALIZA WYNIKOW ---

# 1. Wyznaczenie empirycznej sredniej czasu oczekiwania
srednia_empiryczna <- mean(czasy_czekania)
print(paste("Sredni czas oczekiwania:", round(srednia_empiryczna, 2), "
   minut"))

# 2. Wyznaczenie mediany oraz odchylenia standardowego
mediana_empiryczna <- median(czasy_czekania)
```

```r
sd_empiryczne <- sd(czasy_czekania)
```

3. Wizualizacja empirycznego rozkładu (Histogram)

Aby w pełni zrozumieć strukturę czasu oczekiwania, wygenerujemy histogram uzyskanych danych za pomocą wbudowanej funkcji `hist()`. Na wykres naniesiemy linie referencyjne oznaczające intuicyjną średnią oraz rzeczywistą średnią empiryczną.

```r
# Rysowanie histogramu czestosci (probability = TRUE, aby skala Y
   odpowiadaala gestosci)
hist(czasy_czekania, breaks = 30, probability = TRUE,
     col = "lightgray", border = "white",
     main = "Empiryczny rozklad czasu oczekiwania na autobus",
     xlab = "Czas oczekiwania (w minutach)", ylab = "Gestosc
   prawdopodobienstwa")

# Dodanie linii referencyjnej dla intuicyjnej sredniej (5 minut) -
   linia niebieska
abline(v = 5, col = "blue", lty = 2, lwd = 2)

# Dodanie linii referencyjnej dla uzyskanej sredniej empirycznej (~10
   minut) - linia czerwona
abline(v = srednia_empiryczna, col = "red", lty = 1, lwd = 2)

# Dodanie legendy do wykresu
legend("topright", legend = c("Intuicja (5 min)", "Empiria (~10 min)"),
       col = c("blue", "red"), lty = c(2, 1), lwd = 2)
```

4. Pytania analizujące do zadania

- Przyjrzyj się kształtowi słupków na histogramie. Jaki znany rozkład przypomina uzyskany empirycznie rozkład czasu oczekiwania?
- Porównaj uzyskany wykres z gęstością rozkładu wykładniczego odstępów między autobusami. Jakie wnioski można wyciągnąć na temat natury czasu oczekiwania w tym paradoksie?

Zadanie dodatkowe. Estymacja tendencji centralnej w rozkładach skośnych (Wpływ obserwacji odstających)

Opis problemu:
Firma analityczna bada czas procesowania żądań (w milisekundach) na serwerach bazy danych. Większość operacji wykonuje się bardzo szybko, jednak ze względu na sporadyczne blokady tabel, niektóre zapytania trwają ekstremalnie długo. Zjawisko to modeluje się rozkładem o „grubym ogonie" (w naszym eksperymencie użyjemy rozkładu log-normalnego). Pobrano próbkę n pomiarów czasu i zapisano ją w wektorze x. Celem zadania jest porównanie stabilności dwóch estymatorów środka tego rozkładu:

1. $\hat{\mu}_1 = \bar{X}$ (średnia arytmetyczna z próby),
2. $\hat{\mu}_2 = \text{med}(x)$ (mediana z próby).

Polecenie:
Napisz funkcję symulującą pobieranie próby z takiego rozkładu, a następnie za pomocą symulacji Monte Carlo ($N_{sim} = 500$ powtórzeń) porównaj zachowanie obu estymatorów dla próby wielkości $n = 30$. Wyniki przedstaw na wykresie i przeanalizuj wrażliwość obu metod na pojawianie się pojedynczych, ekstremalnych obserwacji odstających.